


# Projet 6 :

## Classez des images à l'aide d'algorithmes de Deep Learning



# Table des matières

**Comment se déroule la  
présentation ?**



**01**

**Contexte**

**02**

**Exploration des  
données**


**03**

**Modélisation**

**04**

**Conclusion**

# 01. Contexte



# 01. Contexte

L'association a accumulé de nombreuses images d'animaux, mais n'a pas le temps de les trier. Nous voulons aider à identifier la race des chiens sur les photos.


Les bénévoles de l'association nous laissent à disposition des données sur le site de « Stanford Dogs Dataset » pour pouvoir entraîner notre algorithme.



L'objectif de ce projet est d'aider l'association à développer un algorithme de détection de race des chiens grâce à des photos.

Pour y arriver, nous allons pré-traiter des images avec des techniques spécifiques et mettre en œuvre une approche de Deep Learning pour parvenir à nos fins.

## 02. Exploration des données



# 02. Exploration des données

6




## Exploration


Des données provenant du site  
« Stanford Dogs Dataset »

Environ 20 000 images pour notre  
modèle.

120 classes de chiens identifiées



n02102318-cocker\_spaniel



n02086646-Blenheim\_spaniel



n02108551-Tibetan\_mastiff




n02092002-Scottish\_deerhound



n02107142-Doberman



n02094114-Norfolk\_terrier



n02087046-toy\_terrier



n02096437-Dandie\_Dinmont



n02098413-Lhasa



# 02. Exploration des données

7

## Traitement des données



- Analyse d'une image
- Transformation des images sous format pixels

01

Batch size : 64 et Epoch : 25  
Pour augmenter la rapidité de traitement et avoir un modèle stable

03

Interpolation :  
Bilinear

02

Redimensionnement :  
Pour avoir la même taille d'image.  
Pour chaque photo.

04

Train - Validation :  
80%- 20%

## Image size

Image taille : 256 x 256 => 224 X 224



```
array([[ 9,  9,  7],  
       [ 9,  9,  7],  
       [ 9,  9,  7],  
       ...,  
       [83, 101, 123],  
       [84, 102, 124],  
       [85, 103, 123]],
```

## Transformation

- Transformation, des images sous format pixels




## 02. Exploration des données



Filtre bilinéaire

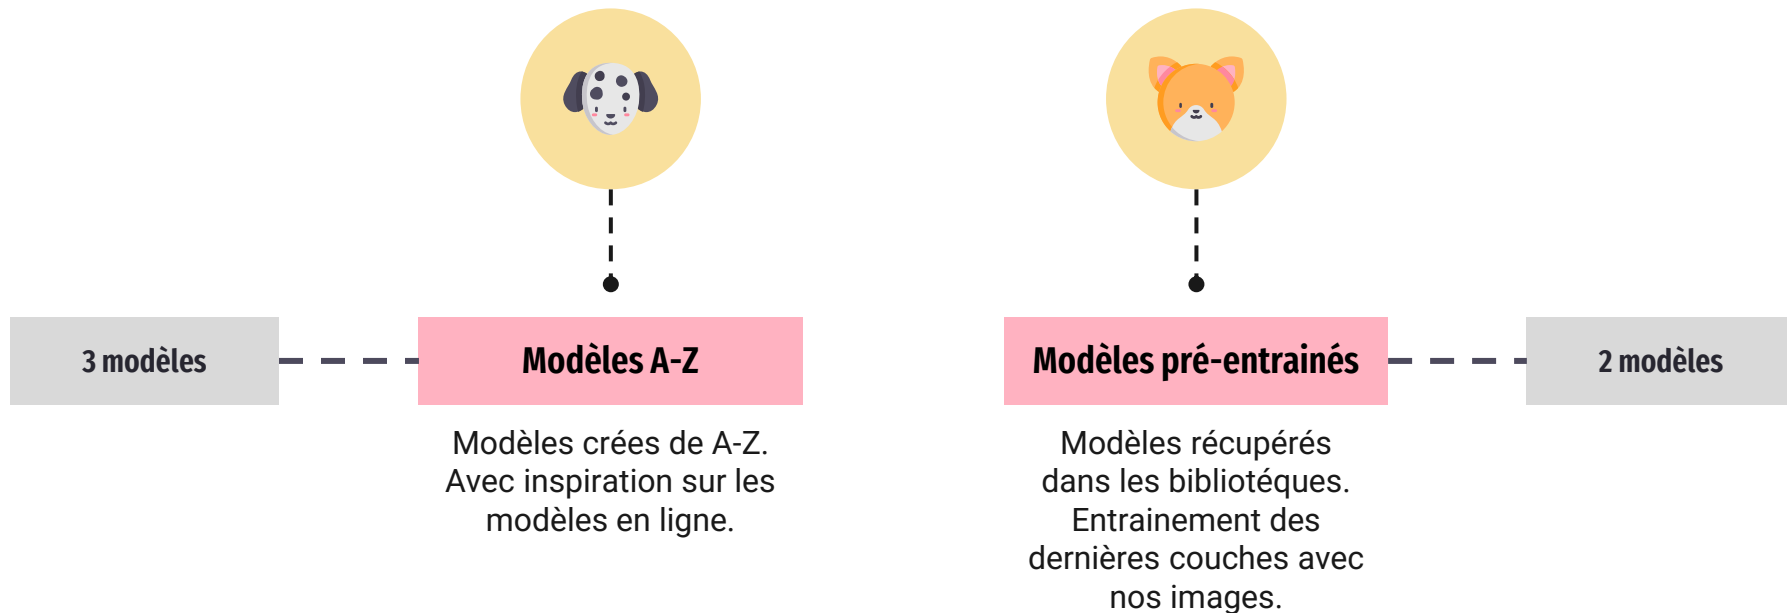
Redimensionnement

Batch Size 64



# 03. Modélisation





# 03. Modélisation

12

## Couche Input

Couche qui spécifie la forme d'entrée.

## Couche Rescaling

Couche qui met à l'échelle les valeurs des pixels des images entre 0 et 1. Cela permet de normaliser les données d'entrée et de faciliter l'apprentissage du modèle en réduisant les variations d'échelle entre les pixels.

## Couche Conv2D

Elle effectue des opérations de convolution pour extraire des caractéristiques spatiales des images. Elles détectent des motifs et des structures dans les données d'entrée, ce qui permet au modèle d'apprendre des représentations de plus haut niveau à partir des pixels bruts.

## Couche MaxPooling2D

Couche qui effectue une opération de pooling pour réduire la dimension spatiale des caractéristiques extraites. Cela permet de réduire le nombre de paramètres et de calculs, tout en préservant les informations les plus importantes.

## Couche Flatten

Cette couche transforme les caractéristiques extraites en un vecteur unidimensionnel. Elle réduit la dimension pour la prédiction. Cela permet de passer de la représentation spatiale des caractéristiques à une représentation linéaire qui peut être traitée par les couches Dense.

## Couche Dense

Couche qui contient le nombre de classes (120) neurones avec une fonction d'activation softmax pour la classification multi classe.

## Couche Dropout

La couche Dropout désactive aléatoirement un pourcentage de neurones à chaque itération, ce qui aide à prévenir le surajustement (overfitting) en encourageant le modèle à généraliser.

## Couche Dense

Ces couches appliquent des opérations linéaires et non linéaires aux caractéristiques extraites. Elles permettent d'apprendre des combinaisons complexes des caractéristiques extraites et de produire des prédictions finales.



# 03. Modélisation

## Modèle

CNN 1 – CNN from scratch

## Layers

10 couches

## Structure

- 1 couches "rescaling"
- 3 couches "Conv2D"
- 3 couches "MaxPooling2D"
- 1 couche "Flatten"
- 2 couches "Dense"

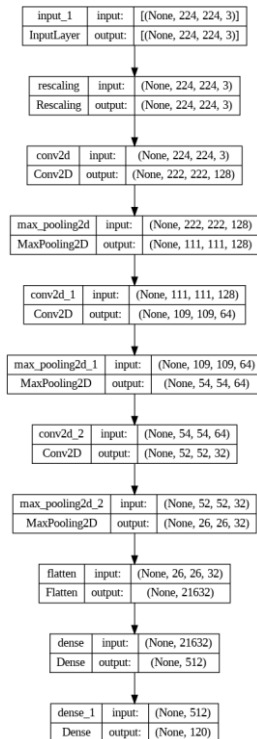


Model: "sequential"

Layer (type)	Output Shape	Param #
rescaling (Rescaling)	(None, 224, 224, 3)	0
conv2d (Conv2D)	(None, 222, 222, 128)	3584
max_pooling2d (MaxPooling2D)	(None, 111, 111, 128)	0
conv2d_1 (Conv2D)	(None, 109, 109, 64)	73792
max_pooling2d_1 (MaxPooling2D)	(None, 54, 54, 64)	0
conv2d_2 (Conv2D)	(None, 52, 52, 32)	18464
max_pooling2d_2 (MaxPooling2D)	(None, 26, 26, 32)	0
flatten (Flatten)	(None, 21632)	0
dense (Dense)	(None, 512)	11076096
dense_1 (Dense)	(None, 120)	61560

=====

Total params: 11,233,496  
 Trainable params: 11,233,496  
 Non-trainable params: 0



## Modèle

CNN 2 – CNN from scratch

## Layers

7 Couches


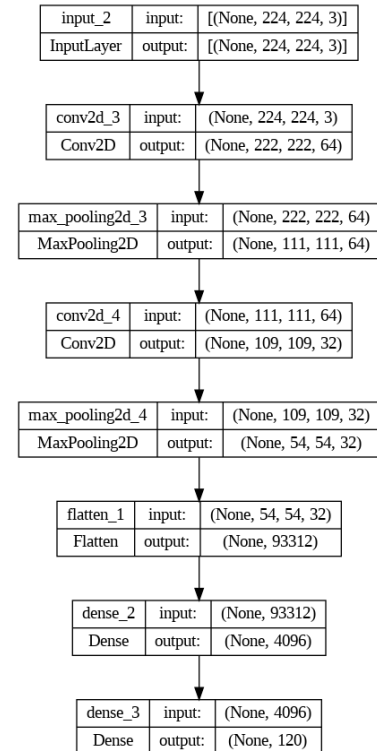
## Structure

- 2 couches "Conv2D"
- 2 couches "MaxPooling2D"
- 1 couche "Flatten"
- 2 couches Dense

Model: "sequential\_1"

Layer (type)	Output Shape	Param #
conv2d_3 (Conv2D)	(None, 222, 222, 64)	1792
max_pooling2d_3 (MaxPooling2D)	(None, 111, 111, 64)	0
conv2d_4 (Conv2D)	(None, 109, 109, 32)	18464
max_pooling2d_4 (MaxPooling2D)	(None, 54, 54, 32)	0
flatten_1 (Flatten)	(None, 93312)	0
dense_2 (Dense)	(None, 4096)	382210048
dense_3 (Dense)	(None, 120)	491640

Total params: 382,721,944  
 Trainable params: 382,721,944  
 Non-trainable params: 0



# 03. Modélisation

## Modèle

CNN 3 – Réseau from scratch

## Layers

12 layers


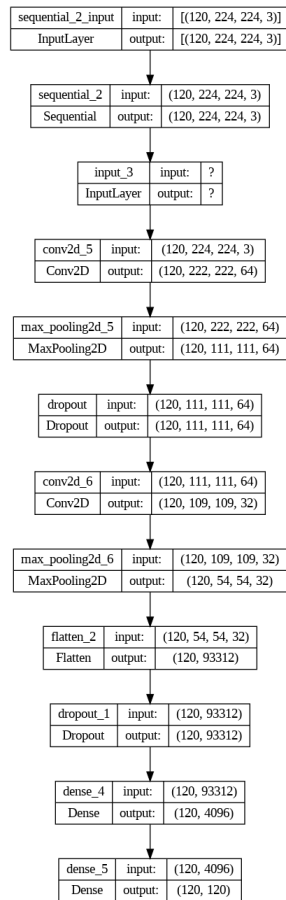
## Structure

- 1 couche data augmentation
- 2 couches "Conv2D"
- 2 couches "dropout"
- 2 couches "MaxPooling2D"
- 1 couche "Flatten"
- 2 couches Dense

Model: "sequential\_3"

Layer (type)	Output Shape	Param #
=====		
sequential_2 (Sequential)	(120, 224, 224, 3)	0
input_3 (InputLayer)	multiple	0
conv2d_5 (Conv2D)	(120, 222, 222, 64)	1792
max_pooling2d_5 (MaxPooling2D)	(120, 111, 111, 64)	0
dropout (Dropout)	(120, 111, 111, 64)	0
conv2d_6 (Conv2D)	(120, 109, 109, 32)	18464
max_pooling2d_6 (MaxPooling2D)	(120, 54, 54, 32)	0
flatten_2 (Flatten)	(120, 93312)	0
dropout_1 (Dropout)	(120, 93312)	0
dense_4 (Dense)	(120, 4096)	382210048
dense_5 (Dense)	(120, 120)	491640
=====		

Total params: 382,721,944  
Trainable params: 382,721,944  
Non-trainable params: 0



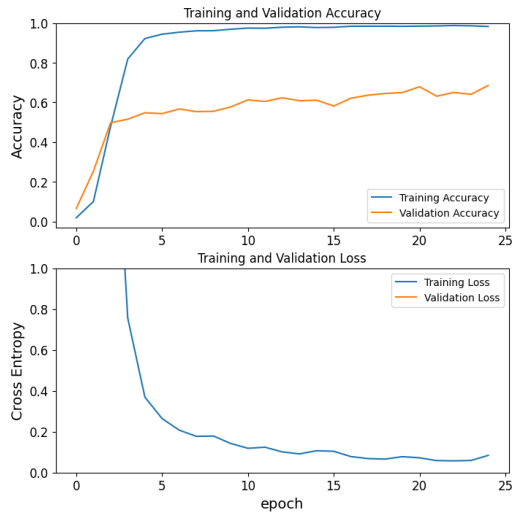
## Modèle 1

CNN 1 : 10 Layers

Résultat améliorable

Train 95%

Validation 68%




## Modèle 2

CNN 2 : 7 Layers

Bon résultat

Train 92%

Validation 72%



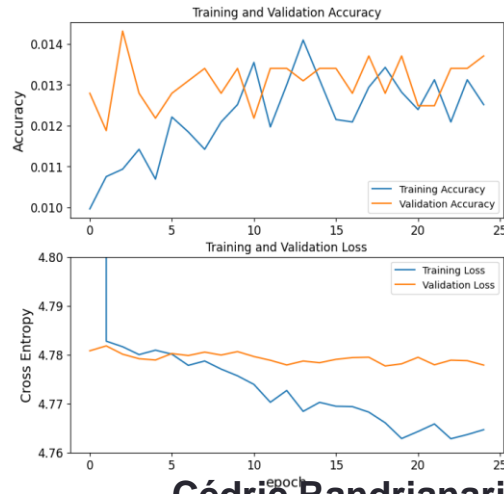
## Modèle 3

CNN 3 : 10 Layers

Mauvais résultats

Train

Validation





# 03. Modélisation

17



ResNet50V2

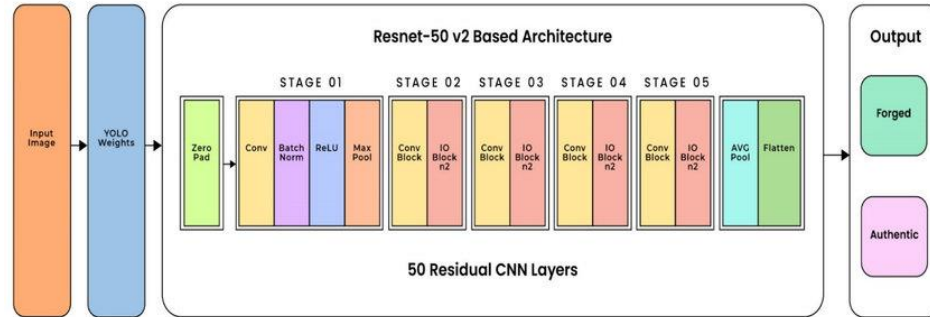
Modèle pré-entraîné

3 couches entraînées

```
# Créer un modèle ResNet50V2 pré-entraîné
base_model = ResNet50V2(include_top=False, weights='imagenet', input_shape=(224, 224, 3))


for layer in base_model.layers:
    layer.trainable = False

# Ajouter des couches de classification personnalisées
x = keras.layers.Flatten()(base_model.output)
x = keras.layers.Dense(4096, activation='relu')(x)
x = keras.layers.BatchNormalization()(x)
predictions = keras.layers.Dense(num_classes, activation='softmax')(x)
```



# 03. Modélisation

18



VGG16

Modèle pré-entraîné

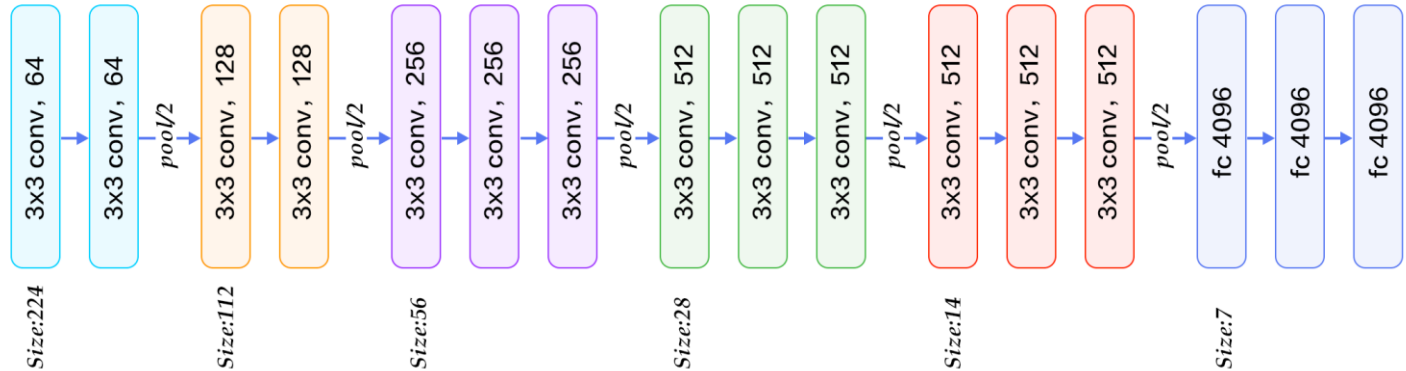
9 dernière couches entraînées

```
base_model = VGG16(weights="imagenet", include_top=False, input_shape=(224,224,3))

for layer in base_model.layers:
    layer.trainable = False

x = keras.layers.Flatten()(base_model.output)
x = keras.layers.Dropout(0.5)(x)
x = keras.layers.Dense(4096, activation='relu')(x)
x = keras.layers.BatchNormalization()(x)
x = keras.layers.Dropout(0.5)(x)
x = keras.layers.Dense(4096, activation='relu')(x)
x = keras.layers.BatchNormalization()(x)
x = keras.layers.Dropout(0.5)(x)
predictions = keras.layers.Dense(num_classes, activation='softmax')(x)

model = keras.Model(inputs=base_model.input, outputs=predictions)
```



# 03. Modélisation


19

## Modèle 1 Transfert learning

CNN transfert learning – ResNet50V2

Bon résultat

Train	93%
Validation	48%




## Modèle 1 Transfert learning

CNN transfert learning - VGG16


Très bon résultat – Modèle retenu

Train	92%
Validation	89%



Cédric Randrianarivelo

# 04. Conclusion





Manque de temps. Plusieurs pistes intéressantes auraient pu être explorées avec plus de temps.



La création d'un réseau de neurones à partir de zéro n'a pas donné des performances satisfaisantes.



Meilleure performance sur le modèle transfert learning.



Certains modèles étaient plus faciles à ajuster avec un nombre de paramètres réduit.



Choix sur VGG16 - Modèle de transfert Learning plus pertinents correction des dernières lignes

## Les axes d'améliorations

### Modèle

Un nombre d' Epoch plus grand pour un meilleur entrainement des modèles. Contrainte de performance - le google colab se déconnecté avec trop d'epoch.

### Chargement image

Le nombre d'échantillons d'entrainement utilisés auraient pu être augmenté. Cela aurait augmenté l'efficacité des calculs et la stabilité de l'apprentissage. Mais augmente l'utilisation de la mémoire.

### Performance



Le projet était bridé par la performance de google colab en termes de GPU. Des solutions cloud ou même une version premium de google collab peuvent être envisagées pour augmenter la performance.

### Traitement des images

Autres traitements à explorer. (ex : Autres filtres que bilinéaire, échelle de gris)

### Transformation des variables

Les pistes de correction du contraste, égalization et débruitage aurait pu être mise en œuvre pour améliorer la performance.



23

**Merci pour votre attention !**

